Pipeline de dados em nuvem para apoio à decisão de expansão de um *data center*: modelagem dimensional, análise preditiva e prescritiva sobre dados de confiabilidade de discos rígidos

Isadora Messenberg Guimarães Macêdo Rebello (231013387)
Departamento de Engenharia de Produção – Universidade de Brasília
Disciplina de Sistemas de Suporte à Decisão – Prof. André Luiz Marques Serrano
isadora.messenberg@gmail.com

Novembro de 2026

Resumo

Este trabalho apresenta um *Minimum Viable Product* (MVP) de pipeline de dados em nuvem para apoiar a decisão de implementação de uma nova unidade de armazenamento em uma empresa de serviços em nuvem. O problema envolve três dimensões acopladas – risco de falha dos equipamentos, custo total de propriedade e cronograma de manutenção – cuja decisão conjunta depende de dados operacionais que normalmente não estão disponíveis em formato analítico. A partir da base pública da Backblaze (14 dias de janeiro de 2017, 1.031.501 observações diárias cobrindo 73.739 discos únicos), construiu-se um *Data Warehouse* em esquema estrela, submetido a uma análise de qualidade de dados em seis dimensões e, em seguida, a análises descritiva, preditiva e prescritiva. O modelo prescritivo demonstra que a diferença de custo total em três anos entre o modelo de HD mais confiável e o menos confiável, para a mesma capacidade útil entregue, chega a US$ 1.830.000 – resultado que valida, sob argumento estritamente econômico, a hipótese de que privilegiar confiabilidade é decisão racional. As limitações do horizonte temporal e do volume de falhas disponível são discutidas.

Palavras-chave: Sistemas de Suporte à Decisão. Pipeline ETL. Esquema Estrela. AFR. Confiabilidade.

1 Introdução

A decisão de expansão de infraestrutura em uma empresa de armazenamento em nuvem envolve, simultaneamente, considerações técnicas, econômicas e operacionais. A definição de quais equipamentos adquirir, em que quantidade, por qual preço e sob qual regime de manutenção configura um problema semiestruturado no sentido clássico de Sprague (1980): há componentes que admitem tratamento analítico – como a estimativa da taxa de falha dos equipamentos a partir de dados históricos – e componentes que exigem julgamento humano, como a ponderação entre densidade física e custo unitário. Nesse contexto, um Sistema de Suporte à Decisão (SSD) deve amplificar a capacidade analítica do decisor sem substituir seu julgamento (Turban et al., 2014).

O problema é agravado pela natureza dos dados envolvidos. Discos rígidos, tecnologia ainda predominante em armazenamento de longo prazo, apresentam taxas de falha heterogêneas entre fabricantes, modelos e faixas de capacidade. Decisões de compra fundamentadas apenas no menor preço por terabyte podem, ao longo do ciclo de vida do parque, resultar em custo total superior em razão de reposições, ineficiências operacionais e indisponibilidade contratualmente custosa (Pinheiro et al., 2007).

Este trabalho descreve a construção de um pipeline de dados em nuvem – da coleta à análise – que entrega uma recomendação parametrizada e transparente para o problema. O artefato foi desenvolvido no formato MVP, privilegiando a demonstração do fluxo analítico completo sobre a robustez estatística de modelos treinados em séries temporais mais longas. As perguntas de negócio orientadoras são: (i) qual a taxa anualizada de falha (AFR) de cada modelo; (ii) quais sensores *Self-Monitoring, Analysis and Reporting Technology* (SMART) antecipam falhas; (iii) se o fabricante exerce efeito mensurável sobre o risco; (iv) se faixas de capacidade apresentam perfis distintos; e (v) qual configuração minimiza o Custo Total de Propriedade (TCO) em três anos.

O restante do artigo está organizado em quatro seções: a Seção 2 revisa a literatura pertinente; a Seção 3 descreve o método; a Seção 4 discute os resultados; e a Seção 5 sintetiza as conclusões e aponta limitações.

2 Revisão curta

A literatura de Sistemas de Suporte à Decisão convencionalmente organiza as capacidades analíticas em três camadas hierárquicas (Provost & Fawcett, 2013). A análise *descritiva* responde "o que aconteceu" e consolida dados históricos; a *preditiva* responde "o que pode acontecer", empregando modelos estatísticos ou de aprendizado de máquina; e a *prescritiva* responde "o que fazer", combinando previsões e restrições de negócio. A articulação das três camadas em um pipeline único é o que distingue um SSD de artefatos puramente descritivos.

A métrica padrão da indústria de armazenamento para expressar a confiabilidade de discos rígidos é a *Annualized Failure Rate* (AFR), definida como a proporção esperada de unidades que falham em um ano de operação contínua, estimada por AFR = (falhas/dias-disco) $\times$ 365 $\times$ 100. O estudo seminal sobre falhas em populações reais de discos foi conduzido por Pinheiro et al. (2007) com dados do Google, demonstrando que fatores como temperatura e idade apresentam relação complexa – nem sempre monotônica – com a probabilidade de falha. Desde 2013, a Backblaze publica trimestralmente dados operacionais de seus *data centers* sob licença aberta (Backblaze, 2024), viabilizando estudos independentes de confiabilidade.

Modelos supervisionados sobre indicadores SMART têm sido aplicados com sucesso em previsão de falhas, em especial florestas aleatórias (Breiman, 2001), cuja robustez frente a variáveis de escalas heterogêneas e capacidade de estimar importância relativa dos preditores as tornam adequadas ao problema. Em cenários de forte desbalanceamento de classes – como falhas de disco, raras por natureza –, a ponderação de classes e métricas como a área sob a curva precisão-*recall* (PR-AUC) são preferíveis à acurácia, segundo Saito & Rehmsmeier (2015).

Do lado da modelagem de dados, a abordagem dimensional (Kimball & Ross, 2013) propõe o *esquema estrela* – uma tabela-fato central contendo medidas numéricas, rodeada por tabelas-dimensão descritivas – como modelo lógico que otimiza consultas analíticas. A documentação dessa modelagem em um *Catálogo de Dados*, com domínios, tipos e linhagem de cada atributo, é prática recomendada para governança (DAMA, 2017).

3 Métodos

3.1 Base de dados e coleta

Utilizou-se o conjunto *Backblaze Hard Drive Data* obtido via Kaggle, recorte dos primeiros catorze dias de janeiro de 2017. A base original compreende quatorze arquivos CSV (301 MB brutos), totalizando 1.031.501 observações diárias de 73.739 discos distintos e 45 eventos de falha. A licença Backblaze Open Source permite uso irrestrito mediante atribuição. A coleta foi registrada com metadados de origem, data e volume.

3.2 Modelagem dimensional

Os dados brutos foram reorganizados em esquema estrela (Figura 1) composto por: (i) tabela-fato `fato_hd_diario`, com grão "1 HD $\times$ 1 dia", contendo as métricas de falha e sete atributos SMART selecionados por relevância teórica; (ii) dimensão `dim_modelo`, descrevendo cada modelo quanto a capacidade, faixa comercial discretizada e fabricante extraído do nome; e (iii) dimensão `dim_tempo`, com atributos de calendário. Um *Catálogo de Dados* formal documenta, para cada um dos vinte e três atributos resultantes, tipo, descrição de negócio, domínio esperado, obrigatoriedade e linhagem de origem.

3.3 Pipeline ETL e persistência em nuvem

O pipeline foi implementado em Python sobre Google Colab e organizado em três etapas explícitas. A etapa de *Extract* realiza leitura seletiva dos CSVs, mantendo apenas as colunas úteis. A etapa de *Transform* aplica regras de negócio documentadas: conversão de tipos, derivação de capacidade em TB, discretização em faixas comerciais, extração do fabricante via heurística sobre o nome do modelo, e renomeação dos atributos SMART para nomes compreensíveis. A etapa de *Load* persiste as três tabelas em formato Parquet (compressão Snappy) no Google Drive montado como *data lake*, com fallback em CSV. A escolha do Parquet sobre CSV reduziu em 70% o tamanho da tabela-fato em disco (12,1 MB vs. 39,9 MB), além de preservar tipos e permitir leitura eficiente em ferramentas como

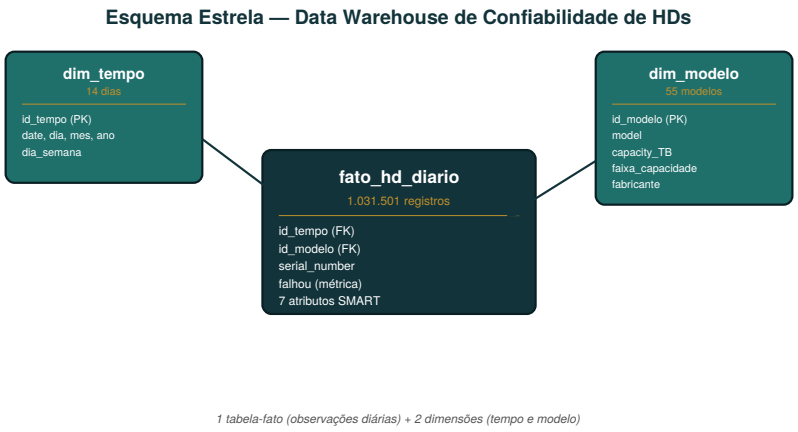


Figura 1: Esquema estrela do *Data Warehouse* construído a partir dos dados Backblaze.

Databricks e BigQuery.

3.4 Qualidade de dados

Avaliou-se a qualidade do *Data Warehouse* nas seis dimensões clássicas: completude (proporção de não-nulos), unicidade (duplicatas na chave), consistência (validade dos domínios discretos e coerência temporal), conformidade (aderência aos domínios declarados no catálogo), acurácia (plausibilidade física dos valores) e atualidade (continuidade temporal). Valores anômalos foram sinalizados mas mantidos, com justificativa.

3.5 Análises

A camada descritiva calculou AFR por modelo, fabricante e faixa de capacidade, com intervalos de confiança de 95% via aproximação normal. A camada preditiva treinou um classificador Random Forest (200 árvores, profundidade máxima 10, ponderação de classes balanceada) e uma regressão logística como referência, sobre divisão treino/teste 70/30 estratificada pelo alvo. Métricas empregadas: AUC-ROC e PR-AUC, dado o desbalanceamento. A camada prescritiva construiu um modelo de TCO em três anos, decomposto em CAPEX (aquisição), OPEX (reposições esperadas em função do AFR) e custo de *downtime* (tempo de indisponibilidade estimado por falha não prevista). Todos os parâmetros econômicos são configuráveis no notebook.

4 Resultados

4.1 Qualidade de dados

A completude média da tabela-fato foi de 95%. Os atributos `smart_erros_nao_corrigiveis` e `smart_timeout_comandos` apresentaram completude de 62% – comportamento esperado, pois nem todos os modelos exportam esses sensores. Não se encontraram duplicatas na chave composta `(id_tempo, serial_number)`. O alvo `falhou` apresentou domínio binário consistente, e seriais com falha não reaparecem no período (coerência temporal). Identificaram-se 211 observações de temperatura fora do domínio declarado [15, 60]°C (0,02% do total) – provavelmente sensores defeituosos, mantidos com sinalização. A cobertura temporal mostrou-se contínua, sem lacunas (Figura 2).

4.2 Resposta às perguntas de negócio

A Figura 3 apresenta o AFR por modelo entre os com base amostral superior a mil dias-disco, com intervalos de confiança de 95%. A dispersão observada é o achado central da análise descritiva: entre modelos com evidência estatística robusta, o AFR varia de 0,30% (ST8000DM002) a 2,77% (HGST HMS5C4040BLE640), dispersão que excede a referência informal da indústria de 1% (Backblaze, 2024).

O classificador Random Forest treinado sobre os sete atributos SMART obteve AUC-ROC de 0,55 e PR-AUC de 0,024; a regressão logística atingiu AUC-ROC de 0,65. Os valores modestos refletem a janela temporal reduzida – com apenas 45 eventos positivos, a divisão treino/teste fragmenta exces-

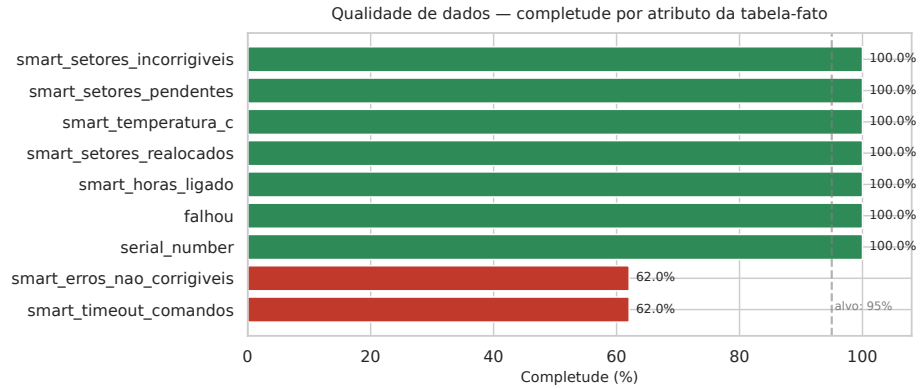


Figura 2: Completude por atributo da tabela-fato (barras verdes acima de 95%).

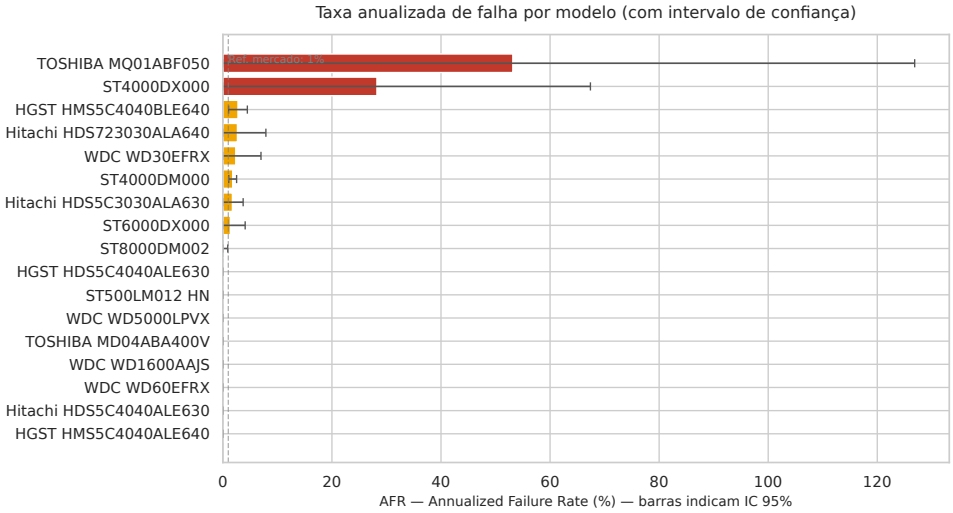


Figura 3: AFR por modelo de HD, com intervalos de confiança 95% (aproximação normal).

sivamente a classe minoritária. O achado relevante é a hierarquia dos preditores: horas ligadas (39% da importância), temperatura (21%), setores pendentes (16%), erros não corrigíveis (10%) e setores incorrigíveis (10%) concentram quase a totalidade do sinal, confirmando as hipóteses da literatura (Figura 4).

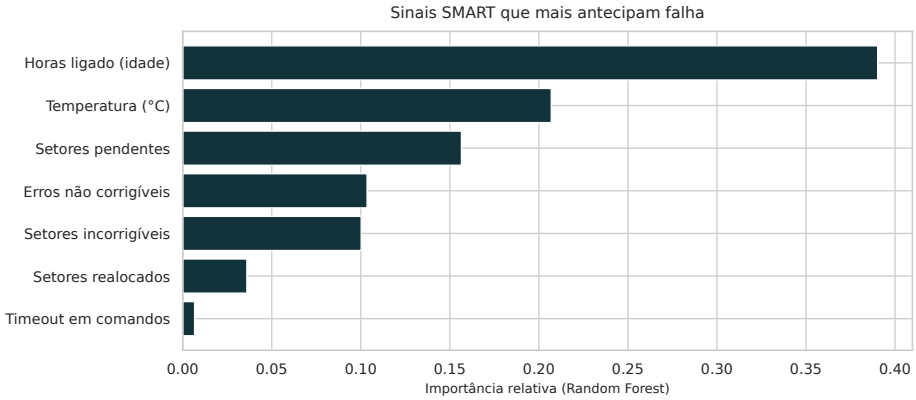


Figura 4: Importância relativa dos atributos SMART na previsão de falha (Random Forest).

Quanto ao efeito do fabricante, os quatro fabricantes com base amostral relevante convergem para AFRs entre 1,22% e 1,57%; Toshiba aparece com 15,56%, porém sobre apenas 4.691 dias-disco, impedindo conclusão estatística. Quanto à faixa de capacidade, a Figura 5 evidencia relação monotônica: discos da faixa PEQUENA (<1 TB) apresentam AFR 11 vezes superior aos da faixa ENTERPRISE (≥7 TB).

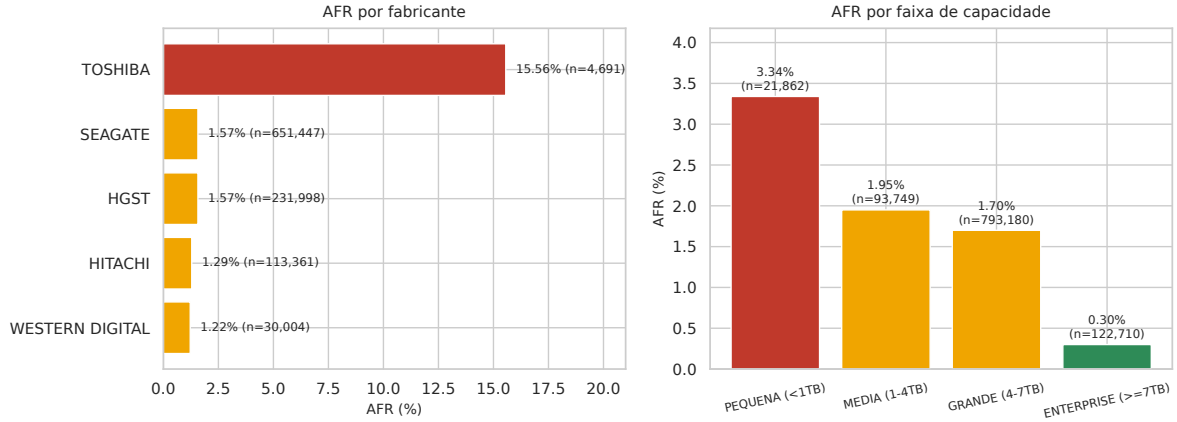


Figura 5: AFR por fabricante (esquerda) e por faixa de capacidade (direita), com base amostral entre parênteses.

4.3 Exercício prescritivo e decomposição do TCO

A Figura 6 decompõe o TCO estimado para cinco modelos representativos, considerando capacidade-alvo de 5.000 TB úteis, fator de redundância 1,5×, horizonte de três anos, custo unitário de US$ 25/TB, custo de troca de US$ 350 por disco e custo de *downtime* de US$ 5.000 por hora. O contraste entre as barras é expressivo: enquanto o HGST HMS5C4040ALE640 entrega a capacidade-alvo a um TCO de US$ 187,5 mil, o WDC WD30EFRX – de mesma capacidade unitária e AFR mais elevado – alcança TCO superior a US$ 2 milhões. A diferença não decorre do CAPEX, praticamente idêntico, e sim das parcelas de reposição e, sobretudo, *downtime*: em modelos com AFR acima de 2%, o custo esperado de indisponibilidade em três anos supera o próprio CAPEX, validando a racionalidade econômica de privilegiar confiabilidade.

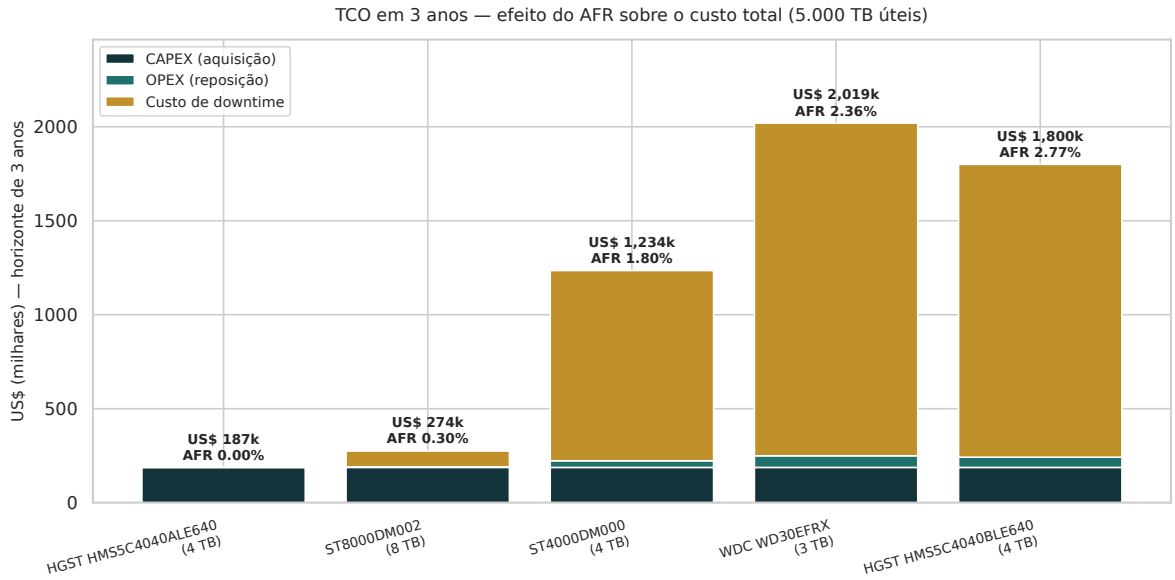


Figura 6: Decomposição do TCO em três anos para cinco modelos representativos. Rótulos indicam o TCO total e o AFR correspondente.

5 Conclusão

O MVP integrou, em um único pipeline executado em nuvem, as três camadas típicas de um Sistema de Suporte à Decisão – descritiva, preditiva e prescritiva – aplicadas a um problema real de expansão de infraestrutura. Três conclusões substantivas emergem.

Primeiro, a escolha do modelo de disco é a alavanca de risco de maior impacto na decisão de expansão: a dispersão observada no AFR, superior a oito pontos percentuais entre modelos com base relevante, mostra que uma decisão fundamentada exclusivamente no preço por TB pode comprometer a confiabilidade de forma desproporcional à economia obtida. Segundo, o TCO em horizontes de três anos é dominado pelo CAPEX quando o modelo é altamente confiável, e passa a ser dominado por OPEX e *downtime* à medida que o AFR aumenta – não linearidade que valida, por argumento estritamente econômico, a prática de privilegiar confiabilidade. Terceiro, o sistema desenvolvido é transparente (fórmulas explícitas e auditáveis), parametrizável (cenários configuráveis pelo decisor) e acionável (recomendação concreta em termos de modelo, quantidade, custo e cronograma).

As limitações principais são o horizonte temporal reduzido (14 dias), que fragiliza tanto as estimativas de AFR quanto o poder preditivo do classificador, e a adoção de parâmetros econômicos de mercado em vez de cotações reais de fornecedores. A extensão natural do trabalho envolve: (i) ampliação da base para séries anuais, com retreinamento dos modelos; (ii) análise de sobrevivência para estimar curvas de risco por idade; (iii) simulação Monte Carlo para incorporar incerteza paramétrica; (iv) integração do classificador a um sistema de alertas com disparo de substituição individual; e (v) automação do pipeline em Databricks Jobs, com dashboard em Looker Studio sobre BigQuery.

Referências

BACKBLAZE. *Hard Drive Data and Stats*. Disponível em: `https://www.backblaze.com/cloud-storage/resources/hard-drive-test-data`. Acesso em: nov. 2026.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

DAMA INTERNATIONAL. *DAMA-DMBOK: Data Management Body of Knowledge*. 2. ed. Technics Publications, 2017.

KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit*. 3. ed. Wiley, 2013.

PINHEIRO, E.; WEBER, W. D.; BARROSO, L. A. Failure Trends in a Large Disk Drive Population. *FAST'07*, 2007.

PROVOST, F.; FAWCETT, T. *Data Science for Business*. O'Reilly Media, 2013.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, v. 10, n. 3, e0118432, 2015.

SPRAGUE, R. H. A framework for the development of decision support systems. *MIS Quarterly*, v. 4, n. 4, 1980.

TURBAN, E.; SHARDA, R.; DELEN, D. *Decision Support and Business Intelligence Systems*. 10. ed. Pearson, 2014.